

Avaliação de Isoladores Elétricos Utilizando Ultrassom e Aprendizado de Máquina

Evaluation of Electrical Insulators Using Ultrasound and Machine Learning

Rafael Bruns¹, Gabriel de Jesus², Luis Augusto Kühn², Andreza Sartori², Luiz Henrique Meyer¹

¹ Departamento de Engenharia de Telecomunicações Elétrica e Mecânica,
Universidade Regional de Blumenau (FURB) – Blumenau, SC – Brazil

² Departamento de Sistemas e Computação,
Universidade Regional de Blumenau (FURB) – Blumenau, SC – Brazil

rafael.brunsl@gmail.com, gsjesus@furb.br, lakuhn@furb.br,
asartori@furb.br, meyer@furb.br

Abstract. *Electric insulators are used in the electric power distribution networks, whose purpose is to provide mechanical support to the cables and electrical insulation from the support structures eg. poles. The evaluation of the installed electrical insulators has a methodology based on the knowledge acquired by technicians and this verification is not performed without the intuitive analysis of a professional. This study presents a methodology based on techniques of signal processing and machine learning for the construction of an algorithm capable of identifying possible damages in electrical insulators. Thus, a study was performed with ultrasound microphone to capture sounds emitted by energized isolators. A set of data for types of insulators were produced in laboratory, one insulator in good condition, and one insulator damaged by drilling. Then, the Decision Trees algorithm was applied, which presented 98.8% accuracy when classifying the samples according to the isolator types studied. Also have been tested the nearest Support Vector Machine and K-Neighbor algorithms, which showed lower accuracy.*

Keywords—*Insulators, Dielectric, Ultrasound, Signal Processing, Machine Learning, Decision Tree.*

Resumo. *Nas redes de distribuição de energia elétrica são utilizados isoladores elétricos, que têm como finalidades dar sustentação mecânica aos cabos e proporcionar isolamento elétrico da estrutura de suporte. A verificação da qualidade dos isoladores elétricos instalados possui uma metodologia baseada no conhecimento adquirido por técnicos, sendo que esta verificação não é realizada sem a análise intuitiva de um profissional. Desta forma, este trabalho apresenta uma metodologia baseada em técnicas de processamento*

de sinais e Aprendizado de Máquina para a construção de um algoritmo capaz de identificar automaticamente possíveis danos em isoladores elétricos. Para isso, foi realizado um estudo com microfone de ultrassom para captação de sons emitidos por isoladores energizados. Para que o algoritmo identifique a integridade dos isoladores, foi necessário passar por um processo de testes com amostras produzidas em laboratório com isoladores em bom estado de conservação e com isoladores danificados por perfuração, sendo possível evidenciar as características dos isoladores. Então, foi aplicado o algoritmo de Árvore de Decisão que apresentou 98,8% de acurácia ao classificar as amostras de acordo com os tipos de isoladores estudados. Foram também testados os algoritmos de Máquina de Vetor de Suporte e K-Vizinho mais próximos, que apresentaram menor acurácia.

Palavras Chave — Isoladores, Dielétricos, Ultrassom, Processamento de Sinais, Aprendizado de Máquina, Árvore de Decisão.

1 INTRODUÇÃO

As redes elétricas de distribuição possuem diversos componentes fundamentais, um deles são os isoladores elétricos, que têm como funções principais a sustentação mecânica e isolamento entre o nível de tensão dos cabos energizados e as estruturas de suporte. Para a verificação da qualidade dos isoladores elétricos instalados nas redes de distribuição são utilizados equipamentos que analisam descargas parciais nos isoladores por ultrassom e convertem em sinais audíveis. Então, um técnico verifica o som emitido pelo equipamento e indica se o isolador possui algum dano ou não.

Com a técnica de inspeção por ultrassom de isoladores, é possível a identificação de problemas intermitentes, que surgem quando determinadas condições se fazem presentes, umidade e contaminação no isolador. Portanto, técnicos com vasta experiência de campo utilizam equipamentos com microfone ultrassônicos Stefenon, Meyer, & Molina, (2015), Stefenon, de Oliveira, Coelho, & Meyer (2017). Acopladores parabólicos que captam e convertem o ultrassom emitido pelos isoladores em decorrência de descargas parciais em uma faixa de frequência e amplitude capaz de sensibilizar o ouvido humano. Então, os técnicos são capazes de indicar quais isoladores estão em bom estado de conservação e quais isoladores devem ser substituídos por estarem danificados, sendo que esta análise é realizada de maneira empírica, de acordo com a experiência previamente adquirida pelo corpo técnico da empresa.

Por este motivo, neste trabalho foram empregadas técnicas de Processamento de Sinais e Aprendizado de Máquina na análise de possíveis danos em isoladores elétricos de forma a tentar excluir o fator humano. As técnicas de Aprendizado de Máquina, área da Inteligência Artificial, constituem uma importante ferramenta para análise de dados com padrões definidos Da Silva Junior, de Aquino, Silva, Neto, Gurgel, de Oliveira, & de Araujo (2018). Neste trabalho, utilizou-se um equipamento de captação de ultrassom sem nenhum tipo de pós-processamento, preservando as características originais do sinal.

A partir do sinal original de ultrassom obtido para isoladores em dois tipos de condição, aplica-se um algoritmo, desenvolvido neste trabalho, de processamento de sinais e um algoritmo de Aprendizado de Máquina, para classificação destes isoladores. Vale ressaltar que a pesquisa bibliográfica não identificou na literatura este tipo e aplicação de aprendizagem de máquina.

Esse artigo está estruturado da seguinte forma: na seção II é apresentada a fundamentação teórica; a seção III é apresentado o detalhamento completo dos experimentos realizados em laboratório e o algoritmo elaborado para classificar os tipos de isoladores; por fim, as seções IV e V apresentam respectivamente os resultados obtidos com os testes e as conclusões.

2 FUNDAMENTAÇÃO TEÓRICA

Esta seção apresenta os fundamentos teóricos que foram necessários para o desenvolvimento do trabalho. A seção A apresenta em detalhes o que são os isoladores elétricos, onde são aplicados e quais suas características técnicas. Na seção B é apresentado um panorama geral do Aprendizado de Máquina e do método de Árvore de Decisões.

2.1 Isoladores Elétricos

Os isoladores são componentes importantes dos sistemas de transmissão e distribuição de energia elétrica, pois tem como principal função a sustentação dos cabos elétricos dos ramais. Por este motivo eles devem ser necessariamente constituídos em material isolante, como por exemplo: porcelana, vidro e materiais poliméricos Stefenon (2015).

De acordo com a ANEEL (Agência Nacional de Energia Elétrica) as redes de distribuição são o conjunto de elementos aéreos ou subterrâneos utilizados para distribuição de energia elétrica, podem ser até 34,5kV. Uma das principais características das redes de distribuição é sua alta capilaridade em zonas urbanas e rurais. As rede aéreas de distribuição estão normalmente em alturas menores que as rede de transmissão e, por isso, estão mais sujeitas ao vandalismo e à contaminação. Por terem ainda uma menor tensão de operação do que as rede de transmissão, também estão mais susceptíveis a danos devido às descargas atmosféricas. Estas características tornam os isoladores de redes de distribuição mais propensos a desenvolverem algum tipo de defeito, e por isso são o foco deste trabalho.

A inspeção de equipamentos elétricos de redes de distribuição é realizada basicamente por instrumentos de ultrassom e rádio interferência, com o intuito de localizar possíveis danos nestes equipamentos Madruga, Scarpini; Meyer; Molina (2013). Os instrumentos de ultrassom são os mais utilizados por serem direcionais e captarem dados apenas do equipamento que se deseja verificar, sendo que este equipamento possui um direcionador de onda para a captação do microfone em distâncias de até 20m Madruga, Scarpini; Meyer; Molina (2013), conforme é

demonstrado na Fig. 1a, onde é apresentado o detalhamento do trabalho de verificação de isoladores de rede de distribuição com microfones de ultrassom, sendo que na fig. 1b é detalhado o microfone de ultrassom.



Figura 1. Detalhamento da utilização de microfone de ultrassom para verificações da qualidade de isoladores da redes elétrica de distribuição, em (a) é apresentado o método de medição e em (b) é apresentado o detalhamento da microfone de ultrassom de maneira ilustrativa.

Pesquisas recentes, como de Stefenon, Meyer & Molina (2015), Stefenon, de Oliveira, Coelho & Meyer (2017), Stefenon, Meyer; Molina (2014) procuram desenvolver sistemas para análise de ultrassom emitido por isoladores de redes elétricas, com o intuito da verificação das formas de ondas de diversos tipos de defeitos. Porém, estes trabalhos utilizam um microfone de ultrassom que primeiramente processa o sinal de ultrassom não audível e converte em som audível. A vantagem na análise dos dados diretamente do microfone de ultrassom, sem processamento prévio, é de que os dados que serão analisados serão os mais fiéis possíveis a leitura.

A análise da qualidade de isoladores por ultrassom é um problema pouco estudado atualmente na engenharia elétrica Da Silva Junior, de Aquino, Silva, Neto, Gurgel, de Oliveira & de Araujo (2018) sendo que as últimas pesquisas nesta área ainda utilizam equipamentos desenvolvidos com técnicas de processamento de sinais rudimentares Stefenon, Meyer, & Molina, (2015), Stefenon, de Oliveira, Coelho, & Meyer (2017). Com as medidas destes equipamentos, tem-se aprimorado as técnicas de detecção da qualidade dos isoladores via ultrassom Stefenon, Meyer & Molina (2015), Stefenon, de Oliveira, Coelho & Meyer (2017), porém, ainda não são utilizados microfones sem processamento prévio de sinal.

Atualmente existem microfones ultrassônicos acoplados em refletores parabólicos, com processamento prévio de sinal, que convertem as altas frequências captadas em som audível. Porém, estes equipamentos exigem técnicos treinados para ouvir e distinguir cada tipo de som, tendo em vista que por si só o equipamento não é capaz de identificar a condição do isolador em análise Vieira (2008).

2.2 Aprendizado de Máquina

O Aprendizado de Máquina consiste na construção de algoritmos computacionais que sejam capazes de tomar decisões com base em dados previamente estudados. O aprendizado de máquina constitui uma das diversas áreas da inteligência artificial. Monard, & Baranauskas (2003).

Mitchell (1997) define que Aprendizado de Máquina é um sistema computacional que aprende a partir de uma determinada experiência, relacionada a uma classe de tarefas. E tem uma medida de desempenho para julgar o desempenho para julgar o desempenho das tarefas realizadas, que irá melhorar com o aumento da experiência.

O Aprendizado de Máquina é dividido em três abordagens: supervisionado, não supervisionado e por reforço. Sendo que neste trabalho foi utilizada a técnica de aprendizado supervisionado. Por sua vez o aprendizado supervisionado é dividido em duas subcategorias: Regressão e Classificação Russel & Norvig (2004). A regressão é aplicada na tentativa de prever resultados de saídas contínuas, já a classificação é aplicada na tentativa de previsão de dados de uma saída discreta Russel & Norvig (2004) Neste trabalho são utilizadas as técnicas de classificação.

2.2.1 Árvores de Decisão

O algoritmo de Árvores de Decisão (*Decision Trees*), é uma das formas mais simples e com altos níveis de acerto de aprendizagem de máquina, sendo que o algoritmo trabalha com a classificação dos exemplos utilizando a classificação booleana, verdadeiro ou falso Russel & Norvig (2004).

O algoritmo divide o problema apresentado em diversos subproblemas menores, e esta divisão é realizada por ordem dos atributos mais importantes, ou seja, os atributos mais importantes constituem os primeiros nós, e assim por diante Russel & Norvig. (2004), Monard & Baranauskas (2003), Jazuli. (2019). O atributo mais importante é considerado de acordo com o item que apresenta maior diferença entre a classificação do exemplo em questão, o intuito de criar uma “hierarquia” entre os itens que apresentam maior importância na classificação dos dados consiste na redução do número de testes necessários, ou seja, na criação de caminhos curtos e uma árvore pouco profunda Russel & Norvig (2004), Monard & Baranauskas (2003), Jazuli (2019).

O conjunto dados utilizados no processo de treinamento do algoritmo é essencial na construção da árvore, mas após a sua construção passa a ser composta apenas por teste dos atributos de cada nó, com valores atribuídos na saída das ramificações e nas saídas finais, denominados nós folha Russel & Norvig (2004), Monard & Baranauskas (2003). Jazuli, H. (2019).

Cabe salientar ainda, que algoritmos de Árvores de Decisão normalmente são os primeiros métodos de Aprendizagem de Máquina a serem utilizados quando há necessidade de classificação, tendo em vista que a sua lógica é passível de entendimento aos humanos Russel & Norvig (2004), Monard & Baranauskas (2003), Jazuli (2019).

2.2.2 Máquina de Vetores de Suporte

A Máquina de Vetor de Suporte (Support Vector Machine – SVM) é um modelo de aprendizagem supervisionado na qual visa construir um hiperplano ótimo, de modo que ele possa separar diferentes classes de dados com a maior margem possível. O SVM é originalmente desenvolvido para realizar uma classificação linear, porém pode executar uma classificação não linear usando o “kernel trick”, isto é, as entradas são implicitamente mapeadas em espaços de recursos de alta dimensão Lima (2004), Hsu, Chang & Lin (2003).

2.2.3 K-vizinhos mais próximos

O algoritmo K-vizinhos mais próximos (*k-Nearest Neighbours* - KNN) se trata de um algoritmo de aprendizado de máquina supervisionado, que apresenta uma fácil implementação e pode executar classificações complexas. Ele é capaz de analisar a proximidade das características que já foram apresentadas para poder classificar novas. O que torna o um algoritmo KNN mais rápido é não necessitar de um treinamento prévio para poder fazer previsões em tempo real, entretanto, não apresenta grande precisão em dados dimensionais devido a dificuldades para poder calcular a distância em cada dimensão Robinson (2018).

3 Metodologia

3.1 Experimento

Neste estudo são utilizados dois isoladores com as mesmas características técnicas, um deles está em perfeito estado de conservação e no segundo foi realizada a perfuração em sua parte superior. O principal objetivo foi demonstrar um equipamento perfurado em decorrência de uma sobretensão muito alta e muito rápida, que seria originada de uma descarga atmosférica na rede elétrica. Em casos reais, esta sobretensão causa a perfuração do isolador e um curto-circuito entre a fase e o pino metálico que está aterrado e sustenta o isolador, há o acionamento da proteção que desliga o circuito, e ao religar o circuito, o isolador volta a funcionar, porém, mantém-se danificado Stefenon (2015).

Não é possível verificar os danos visualmente nos isoladores sem realizar o desligamento do ramal da rede distribuição e inspecionar cada isolador individualmente. Este estudo propõe uma análise preliminar das formas de ondas, que obtidas pelo processamento dos dados de um microfone de ultrassom para um tipo de isolador de porcelana específico. As formas de onda foram captadas em laboratório, conforme

arranjo proposto na fig. 2, onde a distância entre os isoladores e o microfone ultrassônico foi de 0,95m.

O experimento foi conduzido dentro de uma câmara de acrílico, para que fosse possível isolar apenas os sons emitidos pelos isoladores durante os testes.

Na fig. 3 é apresentado o detalhamento geométrico do isolador utilizado nos testes de laboratório, sendo que se trata de um isolador tipo Pino, HI-TOP 15kV, Rosca 1", fabricante Germer, Germer Isoladores. O isolador tem as seguintes características elétricas: tensão nominal suportável a frequência industrial sob chuva de 34kV, tensão nominal suportável de impulso atmosférico de 95kV, tensão nominal de perfuração em óleo de 95kV. E como características mecânicas a distância de escoamento de 230mm e de ruptura mecânica flexão de 1000 kgf.



Figura 2. À esquerda isolador em bom estado de conservação, à direita isolador perfurado, no centro microfone de ultrassom conectado ao computador para análise de dados. Os isoladores e o microfone estão dentro de uma câmara fechada com o intuito de diminuir ao máximo as interferências externas.




Figura 3. Desenho técnico do isolador utilizado nos experimentos Germer Isoladores.

Conforme demonstrado na fig. 4, na base dos isoladores foram instalados os devidos pinos de fixação que são utilizados na rede distribuição e estes pinos foram conectados à terra. Cabe salientar que os pinos de cada isolador só foram aterrados no momento de testes daquele isolador, com o intuito de mitigar interferências entre os isoladores.



Figura 4. Isoladores Classe 15kV utilizados no experimento, conectado ao arco com tensão aplicada de 7,95kV fase terra, que representa os cabos elétricos da rede de distribuição. O cabo conectado no pino de sustentação do isolador está aterrado.

Os isoladores utilizados são apresentados na fig. 5a, onde um dos isoladores está em perfeitas condições de uso e o outro está perfurado. A fig. 5b apresenta o isolador intacto e as fig. 5c e fig. 5d o isolador em que foi realizada uma perfuração central de 3,0 mm de diâmetro com o intuito de representar uma perfuração causada por uma descarga proveniente da rede elétrica.




Figura 5. Detalhamento dos dois isoladores utilizados no experimento: (a) são apresentados os dois isoladores, a esquerda o isolador bom e a direita o isolador perfurado; (b) fundo do isolador bom; (c) vista superior do isolador perfurado; (d) é possível verificar que a perfuração atravessou totalmente o material isolante.

Os isoladores foram fixados com material isolante conforme detalhado na fig. 6, para evitar ruídos ultrassônicos em decorrência da fixação por material condutor (Ex. Cabo de Alumínio), em um aro com tensão aplicada de 12kV, que simula os cabos aéreos que são sustentados pelos isoladores.



Figura 6. Fixação dos isoladores no aro condutor com material isolante para evitar ruídos ultrassônicos de amarrações realizadas com fixação condutora (fita de alumínio).

Para aplicação de tensão foi utilizado um transformador monofásico classe 15kV de acordo com o exposto na fig. 7c, onde com um multímetro indicado na fig. 7a, uma ponteira de média tensão (relação de 1000V x 1V) indicada na fig. 7d e um Variador de Tensão indicado na fig. 7b. Foi aplicada tensão no secundário do transformador (baixa tensão do equipamento), de tal forma, até se obter a tensão de 7,95kV fase terra no primário do transformador (alta tensão do equipamento), conforme apresentado na fig. 7a. Cabe salientar que a foi utilizada a tensão de 7,95kV fase-terra que corresponde a 13,8kV entre fases, que é a tensão de distribuição utilizada pelas concessionárias de energia elétricas neste tipo de isolador.




Figura 7. Arranjo montado para aplicar a tensão no isolador. Onde em “a” é apresentado o medidor de tensão que está conectado a ponteira de média tensão em “d”, que por sua vez está conectada na bucha de alta tensão do transformador detalhado em “c”. É possível aferir a tensão medida no multímetro utilizando o variador de tensão em “b”.

Na captação dos dados foi utilizado um microfone ultrassônico com frequência de amostragem de até 500kHz, apresentado na fig. 8. Os dados foram adquiridos com o software disponibilizado pelo fabricante do microfone, fig. 9, e foram gravados em arquivos em formato WAV (*Waveform Audio File Format*), que posteriormente foram lidos e processados pelo software Matlab® Mathworks.



Figura 8. Microfone ultrassônico utilizado na aquisição de dados, fixado em suporte com o intuito de manter a inclinação fixa para todos os testes.

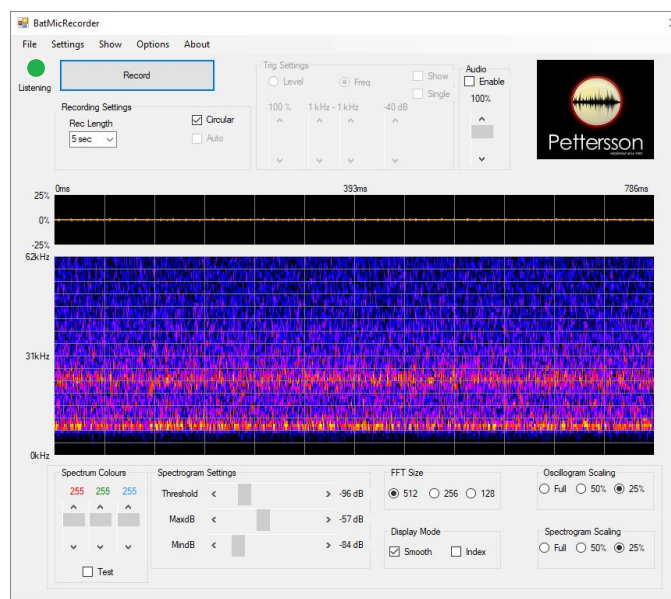


Figura 9. Interface de análise, configuração e gravação das amostras sonoras colhidas pelo microfone, interface fornecida pelo próprio fabricante

Os dados captados pelo microfone foram organizados em 20 gravações diferentes, sendo 10 gravações para o isolador perfurado úmido e 10 gravações para o isolador em bom estado de conservação. Cada gravação teve um tempo total de 5 segundos. O microfone tem uma taxa de amostragem de 500.000 amostras por segundo, portanto, obteve-se o total de 2.500.000 amostras para o período gravado em cada arquivo. Sendo assim, tem-se um total de 50.000.000 de amostras obtidas para os dois isoladores, isto é, 25.000.000 de amostras para cada isolador.

3.2 Tratamento e análise dos Dados

Foi criado um algoritmo no Matlab® para ler os dados gravados em formato WAV e particionar cada arquivo de 5 segundos em vetores que possuem três períodos completos

da rede elétrica, que opera em frequência de 60 Hz conforme detalhado na fig. 10. Cabe salientar que três períodos da rede elétrica foi o menor valor possível de divisão de dados, em decorrência de que a divisão das amostras deve obrigatoriamente resultar em um número inteiro, para que seja possível ter em cada vetor ciclos inteiros da oscilação da rede elétrica. Desta forma, três amostras correspondem a 50ms, portanto cada arquivo de dados foi dividido em 100 vetores com 25.000 amostras cada um. Assim, criou-se uma base de dados amostrados de 1000 vetores para cada um dos dois tipos de isoladores estudados, resultando em um total de 2000 amostras. Cabendo salientar que a divisão das amostras é necessária para obter os dados com o menor número de períodos possíveis da rede elétrica, tendo em vista que os períodos são cíclicos.

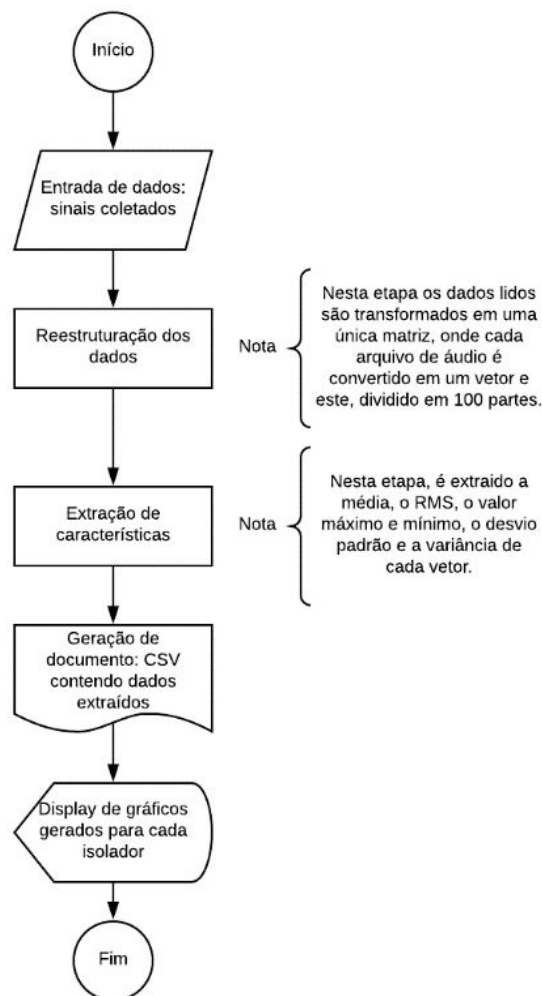


Figura 10. Diagrama de Blocos do tratamento de sinais realizado no Matlab®

Em seguida, os dados foram sobrepostos em dois gráficos de amplitude x tempo, demonstrados nas fig. 11, fig. 12 e fig. 13, onde foi possível identificar visualmente grande diferença entre a amplitude da sobreposição dos sinais sonoros emitido pelo isolador em bom estado e pelo isolador perfurado, foram sobrepostas diversas amostras com o intuito de demonstrar que as amostras ficam restritas ao um determinado nível de amplitude. Com a diferença identificada visualmente nos gráficos, foram utilizados dados intrínsecos para cada sinal, portanto, foram extraídos de cada vetor, o seu valor

médio, o valor RMS (Root Mean Square), o valor Máximo, o valor Mínimo, o Desvio Padrão e a Variância. Estes geraram uma planilha de dados intercalados (entre amostra de isolador bom e isolador danificado), para ser utilizada como base para o algoritmo de Aprendizado de Máquina.




Figura 11. Gráfico da sobreposição das amostras do sinal adquiridas do isolador em bom estado de conservação, onde é possível notar que a amplitude máxima está abaixo de 0,02.




Figura 12. Gráfico da sobreposição das amostras do sinal adquiridas do isolador perfurado, onde é possível notar que a amplitude máxima está acima 0,02.




Figura 13. Sobreposição de duas amostras, uma do isolador bom (Laranja) e uma do isolador perfurado (Azul), onde é possível verificar visualmente a diferença entre os dois tipos de sinais amostrados.

3.3 Algoritmos de Aprendizado de Máquina

Nesta seção é apresentado o detalhamento dos algoritmos construídos na linguagem de programação Python® Python Software Foundation, utilizando técnicas de Aprendizado de Máquina com o intuito de possibilitar a classificação dos sinais amostrados.

Com os dados tratados, foi então desenvolvido a implementação de um algoritmo detalhado na fig. 14 que utiliza técnicas de normalização para facilitar o aprendizado dos algoritmos, e a partir disso, utiliza técnicas de Aprendizado de Máquina para criar, treinar e aprimorar os algoritmos classificadores.

Foram escolhidos três algoritmos para realizar a tarefa de classificação. O primeiro, Árvore de Decisão (*Decision Tree*), pelo fato de a base de dados possuir poucas características de entrada e todas elas serem interpretáveis. Esta abordagem, entretanto, geralmente atinge uma acurácia menor comparada a outros algoritmos de aprendizado de máquina, justificando o uso de outros algoritmos.

Como segunda opção foi escolhido o algoritmo de Máquina de Vetores de Suporte (*Support Vector Machine - SVM*). Dado a quantidade de características de entrada, as SVM são eficientes em encontrar um hiperplano ótimo para classificar os dados.

Por fim, K-vizinhos mais próximos (K-Nearest Neighbors) foi utilizado pois tende a obter uma boa performance, até mesmo para conjuntos passíveis de ruído, como no caso de sinais de isoladores elétricos.

Para todos os algoritmos, foi utilizada a acurácia como métrica de acertos e erros, pois ela indica a fração das previsões que o modelo acertou Google (2019).

A tabela 1 apresenta o detalhamento da planilha de atributos que foi construída para o treinamento e teste do algoritmo, que consiste na organização dos dados extraídos pelo microfone. Esta organização apresentada é aplicada a cada vetor e representa respectivamente na ordem de colunas da esquerda para a direita: na primeira o classificador, na segunda a média, na terceira o valor RMS, na quarta o valor máximo, na quinta o desvio padrão e na sexta a variância. Cabe salientar que a planilha de classificadores apresenta um total de 2000 linhas de dados e que o classificador 1 corresponde ao isolador em bom estado de conservação e seco, e o classificador 5 corresponde ao isolador perfurado e úmido.

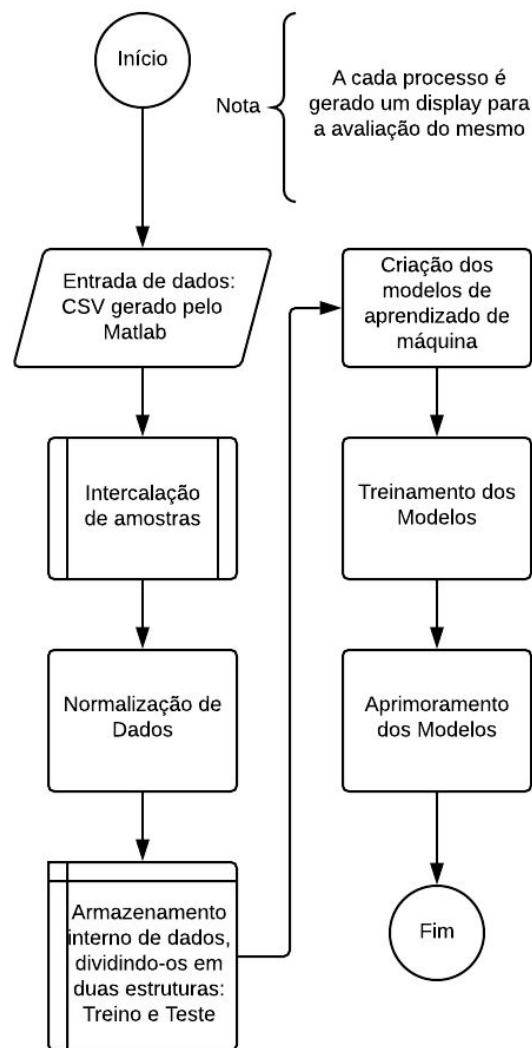


Figura 14. Diagrama de Blocos do Algoritmo criado em Python

Os valores detalhados na planilha de dados não estão normalizados, conforme apresentado na fig. 15, ou seja, o intervalo de valores possíveis de se assumir para cada coluna são diferentes, dificultando até mesmo para identificar visualmente todos os atributos no gráfico. Esta característica pode influenciar no aprendizado dos algoritmos,

dando um peso maior para as entradas que possuem o maior valor absoluto, destacando-se as entradas que representam os valores de máximo e de mínimo. Portanto, visando facilitar o aprendizado do modelo, foi necessário criar uma etapa de pré-processamento para normalizar os dados e colocá-los em uma única escala, conforme mostra a fig. 16, onde é possível identificar visualmente todas as seis características dos vetores.

Para realizar tal normalização, foi utilizada a técnica *min-max normalization*, a qual realiza uma alteração linear nos dados originais, podendo ser determinado o intervalo de valor desejado Saranya & Manikandan (2013). Para mapear um valor v , de um atributo A do intervalo $[\min A, \max A]$ para um novo intervalo $[\text{new_min}A, \text{new_max}A]$, o cálculo é dado por:

$$\frac{v - \min A}{\max A - \min A} (\text{new_max}A - \text{new_min}A) + \text{new_min}A \quad (1)$$

TABELA I Planilha com classificadores e atributos

Class	Média	RMS	Maximo	Mínimo	Desvio Padrão	Variância
1	0,0000266	0,0018450	0,0119629	-0,0108643	0,0018449	0,0000034
5	0,0000216	0,0040557	0,0189209	-0,0155945	0,0040557	0,0000164
1	0,0000249	0,0018533	0,0160217	-0,0121155	0,0018532	0,0000034
5	0,0000264	0,0038058	0,0196838	-0,0174866	0,0038058	0,0000145
1	0,0000263	0,0018682	0,0162659	-0,0115051	0,0018681	0,0000035
5	0,0000218	0,0038001	0,0154419	-0,0216980	0,0038001	0,0000144
1	0,0000260	0,0018774	0,0138550	-0,0115662	0,0018773	0,0000035
5	0,0000272	0,0038808	0,0209045	-0,0159912	0,0038808	0,0000151
1	0,0000262	0,0019163	0,0131836	-0,0128784	0,0019162	0,0000037
5	0,0000230	0,0040200	0,0197449	-0,0158691	0,0040200	0,0000162
1	0,0000255	0,0019146	0,0129700	-0,0112610	0,0019145	0,0000037
5	0,0000229	0,0041085	0,0188293	-0,0148315	0,0041085	0,0000169
1	0,0000259	0,0019177	0,0140991	-0,0117493	0,0019176	0,0000037
5	0,0000254	0,0037830	0,0179749	-0,0178223	0,0037830	0,0000143
1	0,0000257	0,0019496	0,0118408	-0,0111389	0,0019494	0,0000038
5	0,0000237	0,0038062	0,0214844	-0,0167542	0,0038062	0,0000145
1	0,0000257	0,0018984	0,0146484	-0,0105286	0,0018982	0,0000036
5	0,0000240	0,0037787	0,0176697	-0,0177307	0,0037787	0,0000143
1	0,0000248	0,0019500	0,0153198	-0,0133362	0,0019499	0,0000038
5	0,0000234	0,0038735	0,0233154	-0,0169678	0,0038735	0,0000150
1	0,0000264	0,0019640	0,0124512	-0,0101929	0,0019638	0,0000039
5	0,0000248	0,0037255	0,0160522	-0,0164490	0,0037255	0,0000139
1	0,0000259	0,0018731	0,0137024	-0,0106506	0,0018730	0,0000035
5	0,0000241	0,0036732	0,0180359	-0,0175171	0,0036732	0,0000135
1	0,0000250	0,0019269	0,0150452	-0,0114746	0,0019267	0,0000037
5	0,0000239	0,0037586	0,0174561	-0,0169067	0,0037586	0,0000141
1	0,0000257	0,0019461	0,0130005	-0,0147705	0,0019460	0,0000038

Desta maneira, todos os dados de entrada foram normalizados e escalados para o intervalo fechado entre zero e um, conforme detalhado na fig. 16.




Figura 15. Gráfico com o detalhamento das variações dos atributos das 2000 amostras no eixo “Y” está detalhada a amplitude dos dados não normalizados e no eixo “X” está detalhado o número de amostras, ou seja, cada amostra tem um valor para cada uma das características estudadas.

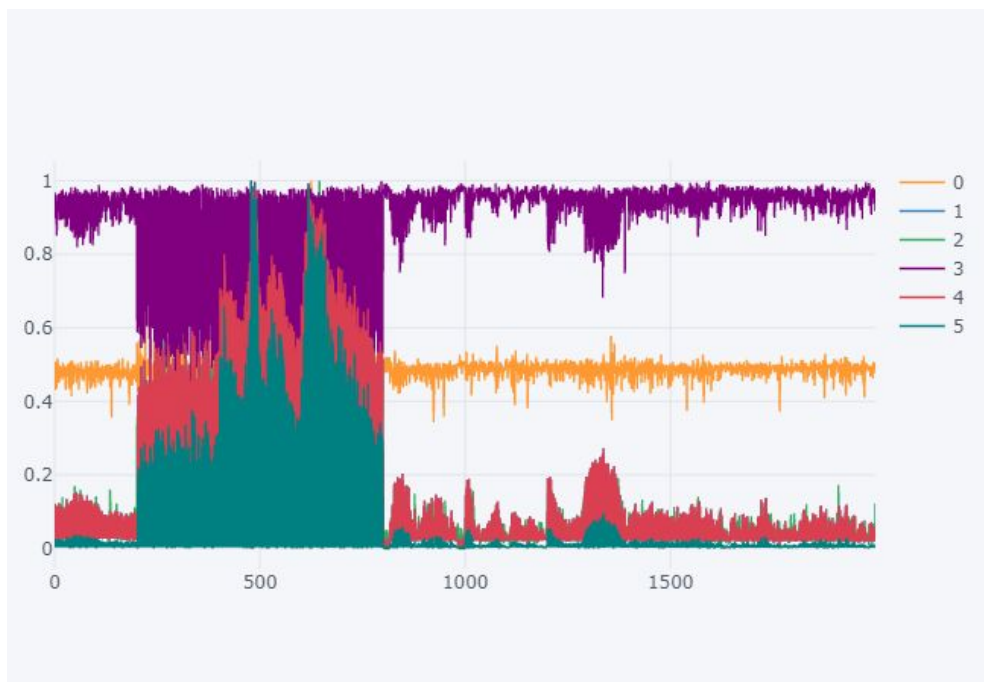


Figura 16. Gráfico normalizado com o detalhamento das variações dos atributos das 2000 amostras, no eixo “Y” está detalhada a amplitude dos dados normalizados

e no eixo “X” está detalhado o número de amostras, ou seja, cada amostra tem um valor para cada uma das características estudadas.

A legenda da fig. 16 está dividida como sendo: “0” o valor Médio, “1” o valor RMS, “2” o valor Máximo, “3” o valor Mínimo, “4” o Desvio Padrão e “5” a Variância.

Para assegurar a confiabilidade e aplicabilidade dos modelos de Aprendizado de máquina em uma situação real, foi dividido o conjunto de dados de treino com 75% das amostras, ficando 25% das amostras reservadas apenas para teste. Desta maneira, os modelos podem aprender as características relevantes para a classificação apenas com o conjunto de treino e então, medir sua confiabilidade com dados nunca vistos anteriormente pelo algoritmo.

Após a aquisição, adequação e normalização dos dados, foram implementados os modelos de Aprendizado de máquina *Support Vector Machine*, *K-Nearest Neighbors* e *Decision Tree*, com intuito de classificar o estado dos isoladores elétricos. Por fim, estes algoritmos foram validados em um conjunto de testes, medindo a acurácia de tais algoritmos em um conjunto de dados nunca vistos anteriormente por eles.

Após a validação dos algoritmos, com intuito de encontrar os melhores parâmetros para os modelos, foi utilizada a técnica de *Grid Search*, que consiste na especificação de um conjunto finito de valores para cada hiperparâmetro à ser otimizado, com isto, o algoritmo pesquisa a grade formada e avalia o produto cartesiano desses conjuntos Feurer, M., Hutter, F. Com esta etapa concluída, os modelos foram novamente avaliados em um conjunto de dados de teste, possibilitando comparar suas precisões e validar os aprimoramentos realizados.

4 Resultados

A partir dos algoritmos treinados, estes foram submetidos a teste, obtendo nesta etapa, 67,8%, 97,0% e 96,6% de acurácia para os modelos *Support Vector Machine*, *K-Nearest Neighbors* e *Decision Tree* respectivamente. Por mais que este resultado seja satisfatório para a aplicação, decidiu-se aprimorar o algoritmo a fim de alcançar uma maior acurácia. Para isto, foi utilizada a técnica “*Grid-Search*”.

Nesta etapa, foi aprimorado para o algoritmo *Support Vector Machine*, os atributos *C e degree*, encontrado como parâmetros para *C* o valor 2 e para *Degree* 2 (aprimorados de 1 e 3). Para o algoritmo *K-Nearest Neighbors* foi aprimorado os atributos *algorithm* de ‘auto’ para ‘ball_tree’, *n_neighbors* de 5 para 2 e *weights* de ‘uniform’ para ‘distance’. Por fim, para o algoritmo *Decision Tree*, foi aprimorado o atributo *min_impurity_decrease* de 0 para 0,05.

Após o aprimoramento dos algoritmos, foi obtido 78,0% de acurácia para o *Support Vector Machine*, 97,6% para o *K-Nearest Neighbors* e 98,8% para o algoritmo *Decision Tree*. Desta maneira, ambos os algoritmos obtiveram uma boa acurácia nos conjuntos de testes, se destacando o algoritmo *Decision Tree* (Árvore de Decisão), o qual obteve uma melhora de 2,2% em suas classificações. Com isso, o modelo de Aprendizado de Máquina proposto chegou a 98,8% de acerto na classificação dos tipos de isoladores, obtendo desta maneira, 494 acertos e apenas 6 erros no conjunto de teste.

Destaca-se a utilização do algoritmo de Árvore de Decisão para a classificação de estados de isoladores elétricos, pois dentre os 500 exemplos separados para teste, em

que o algoritmo não teve acesso durante seu treinamento, ele obteve um total de 494 acertos e apenas 6 erros. ambos os algoritmos obtiveram uma boa acurácia nos conjuntos de testes, se destacando o algoritmo de Árvore de Decisão, o qual obteve uma melhora de 2,2% em suas classificações. Com isso, o modelo de Aprendizado de Máquina proposto chegou a 98,8% de acerto na classificação dos tipos de isoladores, obtendo desta maneira, 494 acertos e apenas 6 erros no conjunto de teste.

Com estes resultados, pode-se observar que o algoritmo construído é capaz de classificar com alta precisão se o isolador elétrico está em um bom estado de conservação ou com falhas de perfuração.

Cabendo salientar que se trata de um estudo em fase inicial, por este motivo os sinais dos isoladores foram obtidos em laboratório, destacando também que foram utilizados apenas isoladores de uma mesmo modelo e classe de tensão.

Estes resultados possibilitam fazer o uso dos algoritmos em trabalhos futuros de diversas maneiras, salientando o uso das árvores de decisões. A primeira delas seria utilizá-los como um classificador binário, servindo para a detecção de perfurações em um isolador elétrico, se tornando desta maneira, parte de um classificador de múltiplas classes. Também, é possível tomá-lo como ponto de partida para a criação de um novo algoritmo cujo predições levam em conta outros tipos de falhas possíveis de ocorrer.

5 Conclusão

Este trabalho apresentou uma metodologia baseada em técnicas de processamento de sinais e Aprendizado de Máquina para a construção de um algoritmo capaz de identificar automaticamente possíveis danos em isoladores elétricos.

Para isso foram coletadas amostras de ultrassom com tensão aplicada de 7,95kV, de cada um dos dois isoladores estudados, o primeiro em bom estado de conservação e o segundo perfurado e úmido. Então os dados coletados em laboratório foram organizados na forma de matriz e exportados para um arquivo CSV.

Com isso, foi possível obter um arquivo de dados para produção das formas de onda características de cada tipo de isolador, para que fosse possível produzir um modelo computacional para comparação analítica dos dados. Tendo em vista que para criação dos modelos de Aprendizagem de Máquina utilizados é necessário um banco de dados utilizado no treinamento, para que então esteja apto a classificar novos dados.

Cabe salientar que com a sobreposição das amostras colhidas em laboratório foi possível identificar que as frequências produzidas nos ensaios têm uma característica própria para cada tipo de isolador. Mas não possuem variação significativa entre medidas de um mesmo isolador, sendo possível verificar facilmente as diferenças entre as amplitudes das frequências emitidas por um isolador bom e por um isolador perfurado.

Como algoritmos de Aprendizado de Máquina foram utilizados Árvore de Decisão (Decision Tree), Máquina De Vetores de suporte (Support Vector Machine) e K-Vizinhos mais próximos (K-Nearest Neighbors). Estes apresentaram boa acurácia, mostrando que é possível estender este trabalho para novas configurações.

Com isto, elenca-se algumas sugestões para trabalhos futuros. A primeira é realizar a coleta de mais dados com configurações diferentes de isoladores, como por exemplo: isoladores sujos sem salinidade, isoladores sujos com salinidade, isoladores perfurados sujos etc., bem como a obtenção das formas de onda de ruídos. Pois com isto é possível aumentar a confiabilidade do modelo. Destaca-se também, que outros modelos de Aprendizado de Máquina podem ser utilizados para a classificação destes isoladores. acredita-se ser relevante para esta aplicação, os modelos baseados em Redes Neurais Artificiais, visto que esta abordagem se torna melhor utilizável à medida que a quantidade de exemplos de dados vão aumentando, não deixando de destacar que a precisão destes modelos tem crescido significativamente em aplicações complexas durante os últimos anos Goodfellow, Bengio & Courville (2016).

A medida que o conjunto de dados vai sendo incrementado, e que os modelos de aprendizado de máquina vão se aprimorando, é possível também, realizar a criação de modelos que não classifiquem apenas dois estados dos isoladores, e sim, uma classificação múltipla, contendo a probabilidade de acerto para cada tipo de falha dos isoladores elétricos.

Em uma outra etapa, almeja-se elaborar um algoritmo para realizar a comparação entre as curvas obtidas neste experimento com as curvas obtidas em campo. Após esta etapa deverão ser criados classificadores para tais sinais obtidos. Por fim, existe a intenção da criação de um software para a classificação dos estados dos isoladores elétricos.

Referências

- Stefenon, S. F., Meyer, L. H., & Molina, F. H. (2015) “Real Time Automated Diagnosis of Insulating System Employing Ultrasound Inspection.”, In *XXIII International Conference on Electricity Distribution* (Vol. 23, pp. 1-4).
- Stefenon, S. F., de Oliveira, J. R., Coelho, A. S., & Meyer, L. H. (2017) “Diagnostic of Insulators of Conventional Grid Through LabVIEW Analysis of FFT Signal Generated from Ultrasound Detector”, *IEEE Latin America Transactions*, 15(5), 884-889.
- da Silva Junior, E. T., de Aquino, F. J. A., Silva, D. A., Neto, A. R. R., Gurgel, K. J. A., de Oliveira, A. E. R. M., & de Araujo, A. L. C. (2018) “Corona Effect Detection in Energized Polymeric Insulators Using Machine Learning and Ultrasonic Emissions”, *IEEE Latin America Transactions* 16(6), 1587-1594.
- Stefenon, S. F. (2015), "Estudo das técnicas de inspeção de redes de distribuição para identificação e classificação de defeitos em isoladores através do uso do ultrassom", Dissertação. FURB – Universidade Regional de Blumenau, Santa Catarina.
- ANEEL, “Redes e linhas de distribuição”, disponível em: http://www.aneel.gov.br/busca?p_p_id=101&p_p_lifecycle=0&p_p_state=maximized&p_p_mode=view&_101_struts_action=%2Fasset_publisher%2Fview_content&_101_returnToFullPageURL=http%3A%2F%2Fwww.aneel.gov.br%2Fbusca%3Fp_auth%3DI2i1iKcm%26p_p_id%3D3%26p_p_lifecycle%3D1%26p_p_state%3Dnormal

[%26p_p_state_rcv%3D1&_101_assetEntryId=15054947&_101_type=content&_101_groupId=656835&_101_urlTitle=redes-e-linhas-de-distribuicao&inheritRedirect=true](#), 05 de agosto de 2019.

Madruga, G; Scarpini; F, Meyer; L.H, Molina, F.H. (2013) “A Practical Approach for Detection of Incipient Failure of Ceramic Insulators”, *IEEE Conference on Solid Dielectrics*, Bologna, Italy.

Stefenon, S F, Meyer; L. H, Molina, F. H. (2014), "Analysis of the Ultrasound Emitted from Defective Insulators," in *International Conference on Condition Monitoring and Diagnosis (CMD)*.

G. VIEIRA A. B. (2008) “Estudo da Viabilidade de Utilização da Técnica de Ultrassom Associada ao Processamento Digital de Sinais para Detecção da Ocorrência de Pontos Quentes em Equipamentos Elétricos de Alta Tensão. Dissertação”, Centro Federal de Educação Tecnológica Celso Suckow da Fonseca. Rio de Janeiro.

Monard, M., & Baranauskas, J. (2003). Conceitos sobre aprendizado de máquinas em Sistemas Inteligentes: Fundamentos e Aplicações. Cap. 4.

Mitchell, T. M. (1997) “Machine Learning”, McGraw-Hill.

Russel, S., & Norvig, P. (2004) “Inteligência Artificial”, 2ª. Edição. Rio de Janeiro: Campus.

Monard, M. C., & Baranauskas, J. A. (2003) “Indução de regras e árvores de decisão. Sistemas Inteligentes. Rezende”, SO Editora Manole Ltda, 115-140.

Jazuli, H. (2019) “An Introduction to Decision Tree Learning: ID3 Algorithm”, disponível em: <https://medium.com/machine-learning-guy/an-introduction-to-decision-tree-learning-id3-algorithm-54c74eb2ad55>, 04 de agosto de 2019.

LIMA, C.A.M. (2004) “Comitê de Máquinas: Uma Abordagem Unificada Empregando Máquinas de Vetores-Suporte”, Tese (Doutorado) - Universidade Estadual de Campinas.

Hsu, C. W., Chang, C. C., & Lin, C. J. (2003) “A practical guide to support vector classification”, Department of Computer Science, National Taiwan University, Taipei 106, Taiwan.

Robinson, S. (2018) “K-Nearest Neighbors Algorithm in Python and Scikit-Learn” [S. l.], disponível em: <https://stackabuse.com/k-nearest-neighbors-algorithm-in-python-and-scikit-learn/>, 21 de agosto 2019.

Germer Isoladores “Isolador Tipo Pino Hitop 15kv – Monocorpo – Rosca 1””, disponível em: <http://www.germerisoladores.com.br/produto/isolador-tipo-pino-hitop-15kv-monocorpo-rosca-1/>, 04 de agosto de 2019.

Mathworks “Matlab”, disponível em: <https://www.mathworks.com/products/matlab.html>, acesso em 04 de ago de 2019.

Python Software Foundation “Python”, disponível em: <https://www.python.org/>, acesso em 04 de ago. de 2019.

Google “Classification Accuracy”, disponível em: <https://developers.google.com/machine-learning/crash-course/classification/accuracy>, 10 de setembro de 2019.

Saranya, C., & Manikandan, G. (2013) “A study on normalization techniques for privacy preserving data mining”, International Journal of Engineering and Technology (IJET), 5(3), 2701-2704.

Feurer, M., Hutter, F. “Hyperparameter Optimization”, Seção 1.3.1 parágrafo 1, disponível em: <https://www.automl.org/wp-content/uploads/2018/09/chapter1-hpo.pdf>, 06 de agosto de 2019.

Goodfellow, I., Bengio, Y., & Courville, A. (2016) “Deep learning” MIT press.